


<SW중심대학 대학원 연계형 산학협력프로젝트(제안서)>

과제명		GPU Sharing을 위한 AI 워크로드 프로파일링 및 스케줄링 알고리즘 연구	
참여기업		KISTI, NIA	담당자(직위) 임상혁 책임연구원
책임교수		권 영 우	소속 컴퓨터학부
대표 대학원생	이름	최지훈	휴대폰 010-2742-9227
			이메일 pressx286@gmail.com
참여인원		(참여대학원생) 박사과정: 0 명, 석사과정: 3 명, 학사과정: 추후 결정	
수행기간		2026.3.1. ~ 2026.7.31. (5개월)	
추진배경		○ 국내에 확보된 인공지능 학습·추론용 GPU가 부족한 상황에서, 확보된 GPU의 효율적 사용을 위해 공유·활용의 필요성이 제기 - 특히 GPU를 소량 확보한 대학·연구소·중소기업들이 자원을 공유하며 활용 극대화에 적극 참여하는 오픈소스 기반과 문화 조성이 필요 - 이를 위해, GPU Sharing을 위한 기반 기술을 연구하고 Pilot 프로젝트를 통하여, 학내 유휴 GPU 자원을 공유할 수 있는 SW 플랫폼을 개발하고자 함	
프로젝트 목표 및 내용		<그림/도표를 포함하여 1~2페이지로 작성>	
		○ 학내 유휴 GPU 자원 Aggregation 및 Distribution 인프라 구축 - 자원 풀링(Pooling): 물리적으로 분산된 이기종 GPU(Pro 6000, RTX 4090 등)를 논리적인 단일 자원 풀로 통합하는 클러스터링 환경 구축. - 분산 환경 구성: 컨테이너(Docker, Kubernetes 등) 기반의 가상화 환경을 도입하여 다수의 사용자가 독립적으로 자원을 할당받고 활용할 수 있는 분배 기반 마련. ○ 프로파일링 기반 AI 워크로드 실행 특성 분석 - 워크로드 분류: 학습(Training)과 추론(Inference), LLM과 Vision 모델 등 다양한 AI 워크로드의 구조적 특성 파악. - 성능 병목 분석: 워크로드 실행 시 발생하는 Compute-bound 및 Memory-bound 특성을 프로파일링 도구를 통해 수집. - 맞춤형 할당 기준 마련: 수집된 프로파일링 데이터를 바탕으로 특정 워크로드에 가장 적합한 GPU 스펙과 할당 비율을 결정하는 최적화 알고리즘 기초 설계. ○ 자원 할당 및 모니터링 도구 개발 - 스케줄러 개발: 분석된 특성을 바탕으로 작업 대기열을 관리하고, 가용 GPU 자원을 동적으로 할당 및 회수하는 스케줄링 모듈 구현. - 통합 대시보드 구축: GPU 사용률(Utilization), VRAM 점유율, 전력 소모 및 온도 등의 메트릭을 실시간으로 시각화하여 관리자와 사용자가 직관적으로 파악할 수 있는 웹 기반 모니터링 시스템 개발. ○ 주차별 연구 계획 1단계: 요구사항 정의 및 기반 기술 공부 - 1주차: 오리엔테이션 및 역할 분담, 프로젝트 목표 및 전체 아키텍처 설계 - 2주차: GPU 가상화 및 분산 처리 시스템 기초 스터디 (CUDA, 런타임 환경, MIG/MPS 개념)	



- 3주차: 컨테이너 환경 및 오케스트레이션 툴(Docker, Kubernetes 등) 구성 방법 학습
- 4주차: 학내 유휴 GPU 노드 상태 조사 및 통합 네트워크 요구사항 정의

2단계: 인프라 구축 및 워크로드 프로파일링

- 5주차: 분산된 GPU 노드를 연동하여 단일 클러스터(Aggregation) 초기 환경 세팅
- 6주차: 대표적인 AI 워크로드(LLM 추론, Vision 모델 학습 등) 선정 및 테스트 스크립트 작성
- 7주차: 워크로드 실행 및 GPU 프로파일링 도구(Nsight Systems 등)를 활용한 성능 지표 수집
- 8주차: 워크로드별 특성(Compute-bound vs. Memory-bound) 분석 및 중간 점검

3단계: 스케줄링 알고리즘 설계 및 도구 개발

- 9주차: 분석된 워크로드 특성 기반의 GPU 자원 스케줄링 및 분배(Distribution) 정책 수립
- 10주차: 정책을 반영한 맞춤형 자원 스케줄러 모듈 프로토타입 구현
- 11주차: 노드별 GPU 상태(Utilization, VRAM, 온도, 전력) 수집 에이전트 개발
- 12주차: 관리자 및 사용자용 실시간 통합 모니터링 웹 대시보드(백엔드/프론트엔드) 구축

4단계: 통합 테스트 및 고도화

- 13주차: 클러스터 환경, 스케줄러, 모니터링 대시보드 간의 통합 연동 테스트 및 버그 수정
- 14주차: 다중 사용자 동시 접속 및 다중 워크로드 실행 환경을 가정한 스트레스 테스트 진행
- 15주차: 스케줄링 도입 전후의 자원 활용률 비교 분석 및 프로젝트 결과 문서화

기대효과

- 유휴 자원을 재활용하여 대규모 고성능 워크스테이션 도입 비용 절감 및 연구 효율 증대
- 단순 AI 모델 개발을 넘어, MLOps 및 AI 시스템 인프라(컴파일러, 런타임, 자원 관리)에 대한 실무적 이해도와 개발 역량을 확보할 수 있음
- 향후 대규모 GPU 공유 플랫폼이나 클라우드 기반의 분산 처리 시스템 연구로 확장하기 위한 기초 프레임워크로 활용 예정